AC2a

Nome: Thiago Faro Ribeiro

RA: 235553

Nome: Giovanna Andreoli

RA: 235831

Predição de Câncer

<u>Informações do atributo:</u>

- a) ID Número de identificação
- b) Diagnóstico (M = maligno, B = benigno) (a variável para predefinir)

Lista de exercícios:

1- Ler o dataset "Cancer_diagnostic.csv" e segui os seguintes passos.

```
file_path = 'Cancer_diagnostic.csv'
data = pd.read_csv(file_path)
```

2- Qual é o tamanho do dataset?

3- Verifique colunas e tipos de dados

```
data.info()
✓ 0.0s
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 569 entries, 0 to 568
Data columns (total 33 columns):
     Column
                              Non-Null Count
                                              Dtype
     id
                              569 non-null
                                              int64
 0
 1
    diagnosis
                              569 non-null
                                              object
 2
    radius_mean
                              569 non-null
                                              float64
                                              float64
 3
    texture_mean
                              569 non-null
                              569 non-null
                                              float64
 4
     perimeter mean
 5
                              569 non-null
                                              float64
     area_mean
 6
                              569 non-null
                                              float64
     smoothness_mean
 7
     compactness_mean
                              569 non-null
                                              float64
 8
     concavity mean
                              569 non-null
                                              float64
     concave points_mean
                              569 non-null
                                              float64
9
                                              float64
 10
     symmetry_mean
                              569 non-null
 11
    fractal dimension mean
                              569 non-null
                                              float64
 12
                                              float64
     radius_se
                              569 non-null
                                              float64
 13
                              569 non-null
    texture_se
 14
                              569 non-null
    perimeter_se
                                              float64
 15
                              569 non-null
                                              float64
    area se
 16
                              569 non-null
                                              float64
     smoothness_se
 17
     compactness_se
                              569 non-null
                                              float64
 18
    concavity se
                              569 non-null
                                              float64
                              569 non-null
 19
    concave points_se
                                              float64
. . .
    fractal dimension worst 569 non-null
                                              float64
31
32
    Unnamed: 32
                              0 non-null
                                              float64
dtypes: float64(31), int64(1), object(1)
```


4- Mostra o resumo estatístico do dataset




5- O dataset está balanceado?

O dataset não está balanceado.

6- Mostrar um gráfico de pizza do dataset



7- Mostra o gráfico de boxplot do dataset



8- Tem valores ausentes? Se sim quais?

9- Realiza a padronização (standardization)

```
# Separando os dados em X (features) e y (alvo)

X = data_cleaned.drop(columns=['diagnosis'])

y = data_cleaned['diagnosis']

# Convertendo o rótulo de diagnóstico para valores binários (M = 1, B = 0)

y = y.map(('M': 1, 'B': 0))

# Padronizando os dados

scaler = StandardScaler()


X_scaled = scaler.fit_transform(X)

# Exibindo as primeiras linhas dos dados padronizados

pd.DataFrame(X_scaled, columns=X.columns).head()

> 0.0s
```

10- Se tiver outlier fazer a remoção deles e mostrar o boxplot do dataset.



11- Dividir o dataset em training (80%) e testing (20%)

```
X_train, X_test, y_train, y_test = train_test_split(X_scaled, y, test_size=0.2, random_state=42)

v 0.0s
```

12- Faz a classificação usando o algoritmo KNN com K = 3, K = 5, K = 7 e mostrar as métricas de accuracy, recall e precision para cada K.

```
# Função para treinar e avaliar o modelo KNN com diferentes valores de K

def evaluate_knn(k):
    knn = KNeighborsClassifier(n_neighbors=k)
    knn.fit(X_train, y_train)
    y_pred = knn.predict(X_test)

accuracy = accuracy_score(y_test, y_pred)
    recall = recall_score(y_test, y_pred)
    precision = precision_score(y_test, y_pred)

print(f"K={k}: Accuracy={accuracy:.4f}, Recall={recall:.4f}, Precision={precision:.4f}")

# Avaliando o modelo KNN com K=3, K=5, e K=7

for k in [3, 5, 7]:
    evaluate_knn(k)

    vo.os

K=3: Accuracy=0.9474, Recall=0.9302, Precision=0.9302

K=5: Accuracy=0.9474, Recall=0.9302, Precision=0.9302

K=7: Accuracy=0.9474, Recall=0.9302, Precision=0.9302
```